KNeighborsClassifier (KNN 분류)

사이킷런의 대표적인 거리 기반 분류 알고리즘

1. KNN(K-Nearest Neighbors) 분류란?

KNN 은 새로운 데이터가 들어왔을 때, 학습 데이터 중에서 **가장 가까운 K개 이웃**을 찾아 그 이웃들의 클래스를 기준으로 **다수결**로 분류하는 알고리즘입니다.

> **핵심 아이디어**
> "가까운 데이터는 같은 범주에 속한다"

2. fit()과 predict()의 역할

① fit() : 학습 단계

`fit(X, y)` 단계에서는 **모델이 규칙을 계산하지 않습니다**.
KNN은 학습 데이터 **X와 정답 y를 그대로 저장**하는 방식입니다.

> KNN은 **지연 학습(Lazy Learning)** 알고리즘입니다.
> 학습 시점이 아니라 **예측 시점**에 계산이 집중됩니다.

② predict() : 예측 단계

`predict()` 가 호출되는 순간, 새로운 데이터와 기존 학습 데이터 간의 **유클리드 거리(Euclidean Distance)**를 계산합니다.

유클리드 거리 공식은 다음과 같습니다.

$$d = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2}$$

계산된 거리 기준으로 **가장 가까운 K개**를 선택하고, 그 이웃들의 클래스에 대해 **다수결**로 최종 클래스를 결정합니다.

3. 기본 사용 예제

```
from sklearn.neighbors import KNeighborsClassifier

# 학습 데이터 (특성 1개라도 X는 2차원)
X = [[1], [2], [3], [6], [7], [8]]
y = [0, 0, 0, 1, 1, 1]

model = KNeighborsClassifier(n_neighbors=3)
```

```
model.fit(X, y)          # 데이터 저장 (거리 계산 ❌)

print(model.predict([[4]]))  # 여기서 유클리드 거리 계산 ⭕
```

> **중요 포인트**
> ✓ `fit()` → 데이터 저장만 수행
> ✓ `predict()` → 유클리드 거리 계산 + 다수결

4. 왜 스케일링이 중요한가요?

KNN은 **유클리드 거리**를 사용하므로 특성의 단위가 다르면 거리 계산이 왜곡될 수 있습니다.

- 키(cm) + 몸무게(kg)
- 나이(년) + 소득(원)

> 👉 따라서 KNN에서는 **표준화(StandardScaler)**나 **정규화**를 함께 사용하는 것이 매우 중요합니다.

5. 한 줄 요약

> KNeighborsClassifier는 **predict() 단계에서 유클리드 거리로 이웃을 계산하는 거리 기반 분류 알고리즘**입니다.